

Programmierung und Deskriptive Statistik

BSc Psychologie WiSe 2024/25

Belinda Fleischmann

| Datum | Einheit | Thema | Form |
|----------|-----------------------|---|---------|
| 15.10.24 | R Grundlagen | (1) Einführung | Seminar |
| 22.10.24 | R Grundlagen | (2) R und Visual Studio Code | Seminar |
| 29.10.24 | R Grundlagen | (2) R und Visual Studio Code | Übung |
| 05.11.24 | R Grundlagen | (3) Vektoren, (4) Matrizen | Seminar |
| 12.11.24 | R Grundlagen | (5) Listen und Dataframes | Seminar |
| | Leistungsnachweis 1 | | |
| 19.11.24 | R Grundlagen | (6) Datenmanagement | Seminar |
| 26.11.24 | R Grundlagen | (2)-(6) R Grundlagen | Übung |
| 03.12.24 | Deskriptive Statistik | (7) Häufigkeitsverteilungen | Seminar |
| 10.12.24 | Deskriptive Statistik | (8) Verteilungsfunktionen und Quantile | Seminar |
| | Leistungsnachweis 2 | | |
| 17.12.24 | Deskriptive Statistik | (9) Maße der zentralen Tendenz und Datenvariabilität | Seminar |
| | Weihnachtspause | | |
| 07.01.25 | R Grundlagen | (10) Strukturiertes Programmieren: Kontrollfluss, Debugging | Seminar |
| 14.01.25 | Deskriptive Statistik | (11) Anwendungsbeispiel | Übung |
| | Leistungsnachweis 3 | | |
| 21.01.25 | Deskriptive Statistik | (11) Anwendungsbeispiel | Seminar |
| 28.01.25 | Deskriptive Statistik | (11) Anwendungsbeispiel, Q&A | Seminar |

(3) Vektoren

Charakterisierung

Indizierung

Arithmetik

Attribute

Charakterisierung

Indizierung

Arithmetik

Attribute

Übersicht

- R operiert mit Datenstrukturen (z.B. Vektoren, Matrizen, Listen und Dataframes).
- Die einfachste dieser Datenstrukturen ist ein Vektor.
- Vektoren sind geordnete Folgen von Datenwerten, die in <u>einem</u> Objekt zusammengefasst sind und einem Variablennamen zugewiesen sind.
- Die einzelnen Datenwerte eines Vektors heißen *Flemente* des Vektors
- Vektoren, deren Elemente alle vom gleichen Datentyp sind, heißen atomar.
- Die zentralen Datentypen sind numeric (double, integer), logical, character



• Mit dem Begriff Vektor ist hier immer ein atomarer Vektor gemeint.

Flementarwerte

Numeric (double, integer)

Per default werden numerische Werte (mit oder ohne Dezimalstellen) als double initialisiert. Dezimalzahlen können in Dezimalnotation oder wissenschaftlicher Notation spezifiziert werden. Weitere mögliche Werte sind Inf, -Inf, und NaN (Not-a-Number).

```
h <- 1  # Einelementiger Vektor vom Typ double (1)

i <- 2.1e2  # Einelementiger Vektor vom Typ double (210)

j <- 2.1e-2  # Einelementiger Vektor vom Typ double (0.021)

k <- Inf  # Einelementiger Vektor vom Typ double (unendlich)

1 <- NaN  # Einelementiger Vektor vom Typ double (NaN)
```

Integer werden wie double ohne Dezimalstellen spezifiziert, gefolgt von einem L (long integer).

Logical

TRUE oder FALSE, abgekürzt T oder F.

Character

Anführungszeichen ("a") oder Hochkommata ('a').

Erzeugung mehrelementiger Vektoren

Direkte Konkatenation von Elementarwerten mit c()

Beachte: c() konkateniert die Eingabeargumente und erzwingt einen einheitlichen Datentyp (vgl. coercion)

```
x <- c(1, "a", TRUE)  # character vector ["1", "a", "TRUE"]
```

Erzeugen "leerer" Vektoren mit vector()

Erzeugen "leerer" Vektoren mit double(), integer(), logical(), character()

Erzeugung von Vektoren als Sequenzen

Erzeugen von ganzzahligen Sequenzen mithilfe des Colonoperators :

a:b erzeugt ganzzahlige Sequenzen von a (inklusive) bis b (maximal)

Erzeugen von Sequenzen mit seq()

seq.int(), seq_len(), seq_along() als weitere Varianten

Charakterisierung

Indizierung

Arithmetik

Attribute

Vektoreigenschaften ausgeben

length() gibt die Anzahl der Elemente eines Vektors aus

x <- 0:10 # Vektor length(x) # Anzahl der Flemente des Vektors

[1] 11

typeof() gibt den elementaren Datentyp eines Vektors aus

x <- 1:3L # Vektor typeof(x) # Datentyp des atomic vectors

[1] "integer"

 $v \leftarrow c(T, F, T)$ # Vektor typeof(y) # Der Datentyp des atomic vectors

[1] "logical"

Anmerkung: mode() und storage.mode() werden nicht empfohlen, sie existieren für S Kompatibilität.

is.logical(), is.double(), is.integer(), is.character() testen den Datentyp

is.double(x) # Testen, ob der x vom Typ double ist

is.logical(y) # Testen, ob der v vom Typ logical ist

[1] FALSE

[1] TRUE

Datentypangleichung (Coercion)

Bei Konkatenation verschiedener Datentypen wird ein einheitlicher Datentyp erzwungen. Es gilt ${\sf character} > {\sf double} > {\sf integer} > {\sf logical}$

```
x <- c(1.2, "a")  # Kombination gemischter Datentypen (character schlägt double)
x

[i] "1.2" "a"
typeof(x)  # Erzeugter Vektor ist vom Datentyp character

[i] "character"
y <- c(1L, TRUE)  # Kombination gemischter Datentypen (integer schlägt logical)
y

[i] 1 1
typeof(y)  # Erzeugter Vektor ist vom Typ integer

[i] "integer"</pre>
```

Datentypangleichung (Coercion)

Explizite Coercion mit as.logical(), as.integer(), as.double(), as.character()

```
x <- c(0, 1, 1, 0)  # double Vektor
y <- as.logical(x)  # Umwandlung in logical Vektor
y

[1] FALSE TRUE TRUE FALSE
```

Coercion geschieht aber auch oft implizit:

Г1] З

Charakterisierung

Indizierung

Arithmetik

Attribute

Indizierung

Grundlagen

- Einzelne oder mehrere Vektorkomponenten werden durch Indizierung adressiert.
- Indizierung wird auch Indexing, Subsetting, oder Slicing genannt.
- Zur Indizierung werden eckige Klammern [] benutzt.
- Indizierung kann zur Kopie oder Manipulation von Komponenten benutzt werden.
- Der Index des ersten Elements ist 1 (nicht 0, wie in anderen Sprachen).

Beispiel

```
x <- c("a", "b", "c")  # character vector ["a", "b", "c"]
y <- x[2]  # Kopie von "b" (neues Object), referenziert von y
x[3] <- "d"  # Aenderung von x zu x = ["a", "b", "d"]</pre>
```

Prinzipien der Indizierung in R

- Ein Vektor positiver Zahlen adressiert entsprechende Komponenten.
- Ein Vektor negativer Zahlen adressiert komplementäre Komponenten.
- Ein logischen Vektor adressiert die Komponenten mit TRUE.
- Ein character Vektor adressiert benannte Komponenten.

Indizierung mit einem Vektor positiver Zahlen

```
x <- c(1, 4, 9, 16, 25) # [1, 4, 9, 16, 25] = [1^2, 2^2, 3^2, 4^2, 5^2]

y <- x[1:3] # '1:3' erzeugt Vektor [1, 2, 3], x[1:3] = x[c(1,2,3)] = [1,4,9]

z <- x[c(1, 3, 5)] # 'c(1, 3, 5)' erzeugt Vektor [1, 3, 5], x[c(1, 3, 5)] = [1, 9, 25]
```

Indizierung mit einem Vektor negativer Zahlen

```
x <- c(1, 4, 9, 16, 25) # [1, 4, 9, 16, 25] = [1^2, 2^2, 3^2, 4^2, 5^2]

y <- x[c(-2, -4)] # Alle Komponenten außer 2 und 4, x[c(-2, -4)] = [1, 9, 25]

z <- x[c(-1, 2)] # Gemischte Indizierung nicht erlaubt (Fehlermeldung)
```

Indizierung mit einem logischen Vektor

```
x \leftarrow c(1, 4, 9, 16, 25) # [1, 4, 9, 16, 25] = [1^2, 2^2, 3^2, 4^2, 5^2]

y \leftarrow x[c(T, T, F, F, T)] # TRUE Komponenten, x[c(T, T, F, F, T)] = [1, 4, 25]

z \leftarrow x[x > 5] # x > 5 = [F, F, T, T, T, T], x[x > 5] = [9, 16, 25]
```

Indizierung mit einem character Vektor

Anmerkungen zur Indizierung in R

R hat eine (zu) hohe Flexibilität bei Indizierung

Out-of-range Indizes verursachen keine Fehler, sondern geben NA aus

```
x \leftarrow c(1, 4, 9, 16, 25) # [1, 4, 9, 16, 25] = [1^2, 2^2, 3^2, 4^2, 5^2] 
 y \leftarrow x[10] # x[10] = NA (Not Applicable)
```

Nichtganzzahlige Indizes verursachen keine Fehler, sondern werden abgerundet

Leere Indizes indizieren den gesamten Vektor

```
y <- x[] # y = x
```

Charakterisierung

Indizierung

Arithmetik

Attribute

Elementweise Auswertung

Unitäre arithmetische Operatoren und Funktionen werden elementweise ausgewertet

```
a <- seq(0, 1, len = 11) # a = [ 0.0, 0.1 , ..., 0.9, 1.0]

b <- -a # b = [-0.0, -0.1, ..., -0.9, -1.0]

v <- a^2 # v = [ 0.0^2 , 0.1^2 , ..., 0.9^2, 1.0^2]

w <- log(a) # w = [ln(0.0), ln(0.1), ..., ln(0.9), ln(1.0)]
```

Binäre arithmetische Operatoren werden elementweise ausgewertet

Vektoren gleicher Länge

Vektoren und Skalare

- R erlaubt (leider) auch Arithmetik mit Vektoren unterschiedlicher Länge
- Bei ganzzahligen Vielfachen der Länge wird der kürzere Vektor wiederholt.

• Arithmetik von Vektoren und Skalaren ist ein Spezialfall dieses Prinzips.

· Andernfalls werden die ersten Komponenten des kürzeren Vektors wiederholt.

```
x \leftarrow c(1, 3, 5)  # x = [1, 3, 5], length(x) = 3

y \leftarrow c(2, 4, 6, 8, 10)  # y = [2, 4, 6, 8, 10], length(y) = 5

v \leftarrow x + y  # v = [1, 3, 5, 1, 3] + [2, 4, 6, 8, 10] = [3, 7, 11, 9, 13]
```

Generell sollten nur Vektoren gleicher Länge arithmetisch verknüpft werden!

Fehlende Werte (NA)

- NA steht für "Not Available" und repräsentiert fehlende Werte in R
- Das Rechnen mit NAs ergibt (meist) wieder NA.

| 3 * NA | # Multiplikation eines NA Wertes ergibt NA |
|------------|--|
| [1] NA | |
| | |
| NA < 2 | # Relationaler Vergleich eines NA Wertes ergibt NA |
| [1] NA | |
| [I] NA | |
| | |
| NA^O | # NA hoch 0 ergibt 1, weil jeder Wert hoch 0 eins ergibt (?) |
| [4] 4 | |
| [1] 1 | |
| | |
| NA & FALSE | # NA UND FALSE ergibt FALSE |
| | |
| [1] FALSE | |

Fehlende Werte (NA)

• Auf NA testet man mit is.na() oder anyNA()

```
x \leftarrow c(NA, 5, NA, 10) # Vektor mit NAs
print(x)
[1] NA 5 NA 10
x == NA
                        # Relationaler Vergleich mit NA ergibt NA
[1] NA NA NA NA
is.na(x)
                        # Logisches Testen auf NA für jedes Element
[1] TRUE FALSE TRUE FALSE
anyNA(x)
                        # Logisches Testen auf mind. 1 NA in gesamtem Objekt
[1] TRUE
```

Ungültige Zahlenwerte (NaN)

• NaN steht für "Not a "Number" repräsentiert ungültige Zahlenwerte, z.B. durch undefinierte arithmetische Operationen

```
0/0
                     # 0 durch 0 teilen ist nicht definiert
[1] NaN
sqrt(-1)
                     # Wurzel einer negativen reellen Zahl ist nicht definiert
[1] NaN
```

 In Mathematik und Informatik ist Dividieren durch Null undefiniert. R verwendet jedoch das Konzept "Unendlichkeit": positive Zahlen gehen bei Division durch Null gegen positive Unendlichkeit (Inf), negative gegen negative (-Inf), ähnlich wie Grenzwerte in der Analysis.

```
4/0
[1] Inf
-3/0
                     # Negative reelle Zahlen durch O teilen ist nicht definiert
```

Positive reelle Zahlen durch O teilen ist nicht definiert

[1] -Inf

Ungültige Zahlenwerte (NaN)

• Das Rechnen mit NaN ergibt (meist) wieder NaN.

| 3 * NaN | # Multiplikation eines NaN Wertes ergibt NaN |
|-------------|---|
| [1] NaN | |
| NaN^O | # NaN hoch 0 ergibt 1, weil jeder Wert hoch 0 eins ergibt (?) |
| [1] 1 | |
| NaN < 2 | # Relationaler Vergleich eines NaN Wertes ergibt NA |
| [1] NA | |
| NaN & FALSE | # NaN UND FALSE ergibt FALSE |
| [1] FALSE | |
| NaN & TRUE | # NaN UND TRUE ergibt NA |
| [1] NA | |

Ungültige Zahlenwerte (NaN)

• Auf NaN testet man mit is.nan()

```
y <- c(NaN, 4, NaN, 3) # Vektor mit NaNs
print(y)
[1] NaN
         4 NaN
y == NaN
                         # Relationaler Vergleich mit NaN ergibt NAs
[1] NA NA NA NA
is.nan(y)
                         # Logisches Testen auf NaN für jedes Element
[1] TRUE FALSE TRUE FALSE
any(is.nan((y)))
                         # Logisches Testen auf mind. 1 NaN in gesamtem Objekt
[1] TRUE
```

Leere Werte (NULL)

• NULL zeigt die völlige Abwesenheit eines Werts an, oft genutzt für leere Objekte.

```
w <- c()  # Leerer Vektor
print(w)

NULL

z <- c(1, 2, NULL)  # NULL als Vektorelement wird ignoriert
print(z)  # Vektor hat nur die Elemete (1, 2)

[1] 1 2

print(length(z))  # Die Länge des Vektors beträgt 2

[1] 2</pre>
```

Leere Werte (NULL)

• Das Rechnen mit NULL ergibt leere Objekte

```
3 * NULL
                            # Multiplikation mit NULL ergibt einen leeren numerischen Vektor
  numeric(0)
  NULL < 2
                            # Relationaler Vergleich mit NULL ergibt leeren logischen Vektor
  logical(0)

    Auf NULL testet man mit is.null()

  is.null(NULL)
                            # Logisches Testen auf NULL
  [1] TRUE
  is.null(logical(0))
                            # Leere Vektoren sind nicht äquivalent zu NULL
  [1] FALSE
```

NA, NaN und NULL

- NA repräsentiert allgemein fehlende Werte.
- NaN repräsentiert spezifisch für ungültige numerische Zahlenwerte, etwa das Ergebnis undefininierter arithmetischer Operationen.
- NULL representiert ein leeres Objekt.

[1] FALSE FALSE FALSE FALSE

- Alle drei Begriffe NA, NaN und NULL zählen zu den reserverd words (siehe ?reserved).
- NaN wird auch von is.na() als fehlender Wert erfasst. Umgekehrt z\u00e4hlt is.nan() jedoch nur numerisch ung\u00fcltige Werte (NaN) und schlie\u00ddt allgemeine fehlende Werte (NA) aus.

```
print(y)

[1] NaN 4 NaN 3

is.na(y)  # Logisches Testen auf NA für jedes Element

[1] TRUE FALSE TRUE FALSE

print(x)

[1] NA 5 NA 10

is.nan(x)  # Logisches Testen auf NaN für jedes Element
```

Charakterisierung

Indizierung

Arithmetik

Attribute

Attribute

Attribute sind Metadaten von R Objekten in Form von Schlüssel-Wert-Paaren

Attribute ausgeben lassen mit attributes()

```
a <- 1:3  # Ein numerischer Vektor
attributes(a)  # Aufrufen aller Attribute
```

NULL

→ Atomic vectors haben per se keine Attribute

Attribute aufrufen und definieren mit attr()

```
attr(a, "S") <- "W"  # a bekommt Attribut mit Schluessel S und Wert W attr(a, "S")  # Das Attribut mit Schluessel S hat jetzt den Wert W
```

```
[1] "W" attributes(a)
```

\$S

[1] "W"

Anmerkung

Attribute werden bei Operationen oft entfernt (Ausnahmen sind names und dim)

```
b <- a[1] # Kopie des ersten Elements von a in Vektor b
attributes(b) # Aufrufen aller Attribute von b
```

NULL

Spezifikation des Attributs names gibt den Elementen eines Vektors Namen

 $v \leftarrow c(x = 1, y = 2, z = 3)$ # Elementnamengeneration bei Vektorerzeugung print(v) # Vektorausgabe

x y z 1 2 3

Die Namen können zur Indizierung benutzt werden

v["y"] # Indizierung per Namen

у 2

Zum Definieren und zum Aufrufen von Namen kann auch names () benutzt werden

```
y <- 4:6 # Erzeugung eines Vektors
names(y) <- c("a", "b", "c") # Definition von Namen
names(y) # Elementhamenantruf
```

[1] "a" "b" "c"

Benannte Namen können hilfreich sein, wenn der Vektor eine Sinneinheit bildet

```
p <- c(age = 31,  # Alter (Jahre), Groesse (cm), Gewicht (kg) einer Person height = 198, weight = 75)
print(p) # Vektorausgabe
```

age height weight

Exkurs: Styleguide für Zeilenumbrüche in R Code

Es kommt häufig vor, dass der vollständige Befehl nicht in eine Zeile passt. Um Fehler zu vermeiden und die Lesbarkeit zu gewährleisten, gibt es gängige Formatierleitlinien, wenn Code auf mehrere Zeilen verteilt werden muss:

Funktionsaufrufe. Argumente über mehrere Zeilen verteilen und einrücken

[1] 3.14

Verschachtelte Funktionen. Funktionen und Argumente über mehrere Zeilen verteilen und einrücken

```
print( # Äußere Funktion, auf Ebene 0

c( # Innere Funktion (=1. Argument der äußeren Funktion), auf Ebene 1

sieben = 7.421, # 1. Argument der inneren Funktionen auf Ebene 2; Komma da 2. Arg folgt!

neun = 9.234 # 2. Argument der inneren Funktionen auf Ebene 2

), # Schließen der inneren Funktion auf Ebene 1; Komma, da 2. Arg folgt!

digits=1 # 2. Argument der äußeren Funktion, auf Ebene 1

) # Schließen der äußerden Funktion auf Ebene 0
```

sieben neur

Charakterisierung

Indizierung

Arithmetik

Attribute

Programmierübungen

- 1. Dokumentiere alle in dieser Einheit eingeführten R Befehle in einem R Skript.
- 2. Öffne die R Help Seite der Funktion c(). Zu welchem R-Paket gehört c()?
- 3. Erstelle einen Vektor mit den Zahlen 1, 2, 3 mit dem Colonoperator.
- Überlege dir zum jedem der vier Prinzipien der Indizierung in R ein Beispiel und dokumentiere es im R Skript aus Aufg 1.
- 5. Erzeuge einen Vektor der Dezimalzahlen 0.0, 0.05, 0.10, 0.15, ..., 0.90, 0.95, 1.0.
- 6. Wähle mithilfe positiver Indices die Elemente 0.0, 0.1,..., 0.9, 1.0 dieses Vektors aus.
- 7. Wähle mithilfe negativer Indizes die Elemente 0.0, 0.1,..., 0.9, 1.0 dieses Vektors aus.
- 8. Wähle die letzten 10 Elemente dieses Vektors aus.
- 9. Erstelle einen Vektor, der sowohl Zahlenwerte als auch fehlende Werte (NA) enthält, zum Beispiel (1, 2, NA,
 - 19, NA, 41) und berechne die Summe aller Werte dieses Vektors mit der Funktion sum().
 - Warum gibt die Funktion als Ergebnis NA? Recherchiere dazu auf der Help Page ("?sum").
 - Wie kannst du die Funktion sum() dazu veranlassen, die NA-Werte zu ignorieren und die Summe nur über die vorhandenen Zahlenwerte zu berechnen?

Selbstkontrollfragen

- 1. Beschreibe in einer Übersicht die R Datenstruktur "Atomarer Vektor".
- 2. Erläutere die Funktion des Colonoperators in R.
- 3. Nenne vier Prinzipien der Indizierung in R.
- 4. Erläutere den Begriff der Datentypangleichung (Coercion).
- 5. Erläutere den Begriff des (Vektor)Recyclings.
- 6. Erläutere die Bedeutung des R Datentyps NA.
- 7. Erläutere, wofür Attribute in R nützlich sind.
- 8. Erläutere, was im Zusammenhang mit der Indizierung in R mit "zu hoher Flexibilität" gemeint ist.